

Braucht KI neue Methoden?

Der Engpass ist nicht Fähigkeit, sondern Nachweisbarkeit

Eine evidenzbasierte Prüfung etablierter Vorgehensmodelle — Scrum und TOGAF ADM — für den produktiven Einsatz generativer KI, am Beispiel des KI-gestützten Cloud Solution Architect.

Mustafa Demir

AI & Cloud Solution Architect · KI-Projekt- und Prozessmanagement

Whitepaper · Stand: September 2026

Grundlage: 140 gesichtete Publikationen, 67 zitierte Quellen

Fallbeispiel: *GenAIOps Compliance Gates* (DOI 10.5281/zenodo.19920310)

Inhalt

	Das Verfahren auf einen Blick — Abbildung 1	3
	Executive Summary	4
1	Einleitung	5
	1.1 Ausgangslage · 1.2 Problemstellung · 1.3 Forschungsfrage · 1.4 Abgrenzung	
2	Methodik	7
	2.1 Datenbasis · 2.2 Einstufung der Quellen · 2.3 Limitationen	
3	Die dokumentierte Hauptbarriere: die Verifikationslücke	8
	3.1 Reifegrade · 3.2 Human-in-the-Loop als Notlösung · 3.3 Was Adoption wirklich treibt	
4	Die Gegenthese auf dem Prüfstand	10
	4.1 Die Position · 4.2 Behauptung oder Befund? · 4.3 Die fehlende Evidenzbasis · 4.4 Zwischenfazit	
5	Der Negativbefund: wo KI heute nicht eingesetzt wird	12
	5.1 Planung ja, Prüfung nein · 5.2 Warum die Kontrollpunkte unbesetzt bleiben	
6	Das Mapping: vorhandene Kontrollen gegen KI-Fehlerklassen	14
	6.1 Fehlerklassen · 6.2 Scrum-Kontrollpunkte · 6.3 TOGAF-ADM · 6.4 Die Zirkularitätsgrenze · 6.5 Der Sonderfall Solo	
7	Business Case: Nutzen, Kosten, Compliance-Hebel	18
	7.1 Produktivität · 7.2 Gegenrechnung · 7.3 Augmentation vs. Substitution · 7.4 Compliance	
8	Die Rolle verschiebt sich	21
	8.1 Vom Autor zum Auftraggeber und Prüfer · 8.2 Kompetenzprofil · 8.3 Tech-Stack · 8.4 Deskillung	
9	Instanziierung am laufenden Artefakt	23
	9.1 Der Fall · 9.2 Die vier Ehrlichkeitsfelder · 9.3 Beweisstufen E-0 bis E-3 · 9.4 Abgrenzung	
10	Limitationen und offene Punkte	25
11	Fazit und Handlungsempfehlungen	25
	Quellenverzeichnis	27

Das Verfahren auf einen Blick




Abbildung 1: Der Kontrollkreislauf Mensch–KI in BPMN-2.0-Notation. Die KI arbeitet ausschließlich zwischen zwei Kontrollpunkten: einer vorgelagerten Festlegung (Definition of Ready) und einer nachgelagerten, maschinell erzwungenen Prüfung einschließlich Negativprobe. Der Mensch entscheidet am Anfang und am Ende; die maschinelle Prüfung entscheidet dazwischen. Der Nachweis trägt eine Beweisstufe nach Fälschungskosten. Der Zyklus wiederholt sich je Arbeitseinheit — er endet nicht mit der Lieferung, sondern mit deren Aufzeichnung.

Executive Summary

Unternehmen scheitern beim produktiven Einsatz generativer KI nicht an fehlenden Fähigkeiten der Systeme, sondern daran, dass sie deren Ergebnisse nicht prüffest belegen können. Eine Interviewstudie über zwölf Unternehmen findet sieben auf der niedrigsten von sechs Reifestufen und nur ein einziges in produktiver Mehr-Agenten-Orchestrierung; als Ursache benennen die Autoren ausdrücklich eine *capability-deployment verification gap* — die Fähigkeiten sind vorhanden, aber es fehlen Mechanismen, um deren Ausgabe zu verifizieren (Apostolou et al., 2026a).

Teile der aktuellen Literatur schließen daraus, etablierte Vorgehensmodelle seien überholt und müssten durch KI-native Methodiken ersetzt werden (Bandara et al., 2025). Dieser Bericht prüft diese Position und kommt zu einem anderen Ergebnis. Die Behauptung steht in der Motivationsposition konzeptueller Entwürfe, während das einschlägige systematische Review die dafür nötige empirische Basis ausdrücklich als offene Forschungslücke ausweist (Otoum et al., 2026). Gleichzeitig zeigt ein systematisches Review zu KI in Scrum einen bemerkenswerten Negativbefund: KI-Unterstützung konzentriert sich auf Planung und Schätzung, während für die Phasen *Implement* sowie *Review und Retrospektive* keine einzige Anwendung gefunden wurde (Peras et al., 2026). Die Praxis setzt KI also genau dort nicht ein, wo Scrum seine Kontrollmechanismen hat.

Der Bericht schlägt deshalb die sparsamere Hypothese vor: KI ist ein fehlbarer Mitwirkender, und für fehlbare Mitwirkende existieren seit Jahrzehnten erprobte Kontrollmechanismen — Definition of Ready und Definition of Done, Akzeptanzkriterien, Review, Vier-Augen-Prinzip, Architektur-Governance. Bevor neue Methodiken erfunden werden, ist zu prüfen, ob die vorhandenen tragen. Empirisch spricht dafür, dass die Kompatibilität mit bestehenden Workflows der dominierende Treiber der KI-Adoption ist und klassische Technologieakzeptanzmodelle insoweit herausfordert (Russo, 2023), und dass die Emulation von Prozessmodellen die Qualität KI-erzeugten Codes messbar verbessert — mit Scrum als bestem der geprüften Modelle (Lin et al., 2024).

Der wirtschaftliche Befund ist zweiseitig. Randomisierte Feldexperimente mit 4.867 Entwicklern zeigen 26,1 % mehr abgeschlossene Aufgaben (Cui et al., 2026); eine Metaanalyse über 23 Studien beziffert den Effekt jedoch nur als moderat und im Unternehmenskontext deutlich kleiner als im Labor (Maier et al., 2026). Dem stehen belegte Kosten gegenüber: 22,7 % der von KI eingebrachten Befunde überleben bis zur aktuellen Repository-Version (Liu et al., 2026), und Kernentwickler prüfen 6,5 % mehr fremden Code bei 19 % geringerer eigener Produktivität (Xu et al., 2025). Am Kapitalmarkt trennt sich, was der Bericht methodisch trennt: Augmentation erzeugt Wert, Substitution nicht (Aghbabali et al., 2026).

Für regulierte Branchen ist der Hebel am größten. KI-gestützte Compliance-Automatisierung reduzierte in einer zwölfmonatigen Erprobung bei einer Großbank den manuellen Auditaufwand um 74 % und erkannte 98 % der Regelverstöße präventiv (Sardana et al., 2024); im Auditsektor sind 5,0 % weniger Restatements und 0,9 % geringere Prüfungsgebühren je Standardabweichung KI-Investition nachgewiesen (Fedyk et al., 2022).

Kernaussage. Der Engpass ist nicht die Fähigkeit der KI, sondern die Nachweisbarkeit ihrer Ergebnisse. Wer KI skalieren will, braucht keine neue Methodik, sondern maschinell prüfbare Kontrollpunkte an den Stellen, an denen die vorhandene Methodik sie ohnehin vorsieht — und eine Beweisführung, die nach Fälschungskosten geordnet ist statt nach Automatisierungsgrad.

1 Einleitung

1.1 Ausgangslage: Fähigkeit im Überfluss, Vertrauen im Mangel

Die Verbreitung generativer KI in der Softwareentwicklung ist keine Prognose mehr, sondern Bestand. In einer Erhebung unter Entwicklern geben 79 % an, GenAI täglich zu nutzen; über 70 % berichten, die Zeit für Standardcode und Dokumentation mindestens zu halbieren (Gurgul et al., 2026). Eine Analyse von über 30 Millionen GitHub-Commits schätzt, dass in den Vereinigten Staaten inzwischen rund 29 % der Python-Funktionen von KI geschrieben werden (Daniotti et al., 2025).

Dem steht ein auffälliger Befund gegenüber: Der Sprung von der assistierenden Nutzung zur produktiv eingebundenen, teilautonomen Arbeit gelingt kaum. Eine qualitative Interviewstudie mit sechzehn Praktikern aus zwölf Unternehmen ordnet sieben Unternehmen der niedrigsten von sechs Reifestufen zu, vier der zweiten und nur ein einziges der dritten (Apostolou et al., 2026a). Vier Unternehmen verfügten über weitergehende Fähigkeiten, konnten sie aber nicht in Produktionsabläufe überführen — nicht aus technischen Gründen, sondern weil geeignete Mechanismen zur Überprüfung der Ausgabe fehlten.

1.2 Problemstellung

Aus dieser Diagnose werden in der Literatur zwei gegenläufige Konsequenzen gezogen. Die eine Position hält etablierte Vorgehensmodelle — Agile, Kanban, ShapeUp — für zunehmend unzureichend, weil sie für menschenzentrierte Teams entworfen wurden, und schlägt eine eigens für KI-Agenten konzipierte Methodik vor (Bandara et al., 2025). Die andere Position rückt die Prozesskontrolle selbst in den Mittelpunkt: Das zentrale Problem sei nicht mehr das Prompt Engineering, sondern die Steuerung des Engineering-Prozesses (Koch, 2026).

Die Unterscheidung ist praktisch folgenreich. Wer der ersten Position folgt, investiert in den Aufbau neuer Methodik. Wer der zweiten folgt, investiert in die Instrumentierung vorhandener Kontrollpunkte. Für Unternehmen mit etablierten Managementsystemen — und erst recht für regulierte Branchen mit zertifizierten Informationssicherheits-Managementsystemen — ist das ein Unterschied in Größenordnungen.

1.3 Forschungsfrage und Teilfragen

Hauptforschungsfrage: Müssen etablierte Vorgehensmodelle — Scrum und TOGAF ADM — für den produktiven Einsatz generativer KI ersetzt werden, oder liefern gerade sie die Kontrollmechanismen, die diesen Einsatz erst skalierbar machen?

Nr.	Teilfrage
TF 1	Was ist die empirisch dokumentierte Hauptbarriere der KI-Adoption in Unternehmen?
TF 2	Ist die Gegenthese — etablierte Methoden seien unzureichend — belegt oder behauptet?
TF 3	Wo setzt die Praxis KI heute ein, und wo auffällig nicht?
TF 4	Welche Kontrollmechanismen halten Scrum und TOGAF vor, und auf welche KI-Fehlerklassen antworten sie?
TF 5	Welcher betriebswirtschaftliche Nutzen ist belegt, und welche Kosten stehen dagegen?
TF 6	Wie verändern sich Rolle und Kompetenzprofil des Cloud Solution Architect?
TF 7	Was zeigt die Instanziierung an einem laufenden Artefakt, und wo bleibt sie offen?

1.4 Abgrenzung: Was dieser Bericht nicht leistet

Der Bericht ist keine kontrollierte Studie. Er prüft eine in der Literatur vertretene Position gegen die verfügbare Evidenz und illustriert die Gegenposition an einem einzelnen, laufenden Artefakt. Ein Einzelfall belegt Machbarkeit, nicht Wirksamkeit; die Abschnitte 10.1 und 10.2 führen diese Grenze aus. Der Bericht ist ferner keine Rechtsberatung: Aussagen zum EU AI Act dienen der Einordnung des Anwendungsfalls, nicht der Auslegung.

2 Methodik

2.1 Datenbasis und Suchstrategie

Grundlage sind zehn strukturierte Recherchen in der Metadatenbank Consensus, die Semantic Scholar, PubMed, Scopus und arXiv zusammenführt. Die Suchstränge folgten den sieben Teilfragen: Solo-Anwendung agiler Methoden; KI in Scrum-Prozessen; TOGAF und KI; Architekturentscheidungen und Nachvollziehbarkeit; Produktivitätswirkung; Codequalität und technische Schulden; Unternehmensadoption und Reifegrad; Compliance-Automatisierung; Kompetenzverschiebung; sowie eine abschließende Verifikationssuche zum Neuheitsanspruch der hier vertretenen Position.

Aus rund 140 gesichteten Publikationen wurden 67 mit konkret belegbaren Aussagen übernommen — davon 43 begutachtet und 24 als Preprint. Aufnahmekriterium war, dass eine Arbeit eine im Text getragene Aussage stützt oder ihr widerspricht — Arbeiten, die lediglich das Themenfeld bestätigen, wurden nicht aufgenommen. Widersprechende Befunde wurden bewusst gesucht und sind in Kapitel 7 eigens ausgewiesen.

2.2 Einstufung der Quellen

Jede Quelle ist im Quellenverzeichnis als begutachtet (**[PR]**) oder als Preprint ohne abgeschlossene Begutachtung (**[PP]**) gekennzeichnet. Diese Trennung ist hier nicht formal, sondern inhaltlich geboten: Ein erheblicher Teil der aktuellsten und thematisch nächstliegenden Arbeiten — insbesondere aus dem Jahr 2026 — liegt ausschließlich als arXiv-Preprint mit geringer Zitationszahl vor. Wo eine tragende Aussage allein auf einem Preprint beruht, ist das im Fließtext kenntlich gemacht.

Zusätzlich wurde zwischen zwei Prüftiefen unterschieden. Für die im Text genannten quantitativen Kennzahlen wurde die jeweilige Primärquelle über ihre Metadaten und Zusammenfassung verifiziert. Eine Volltextprüfung sämtlicher Arbeiten war im Rahmen dieser Recherche nicht möglich; die daraus folgende Einschränkung ist in Abschnitt 2.3 benannt.

2.3 Limitationen der Methodik

Erstens beruht die Auswertung überwiegend auf Zusammenfassungen und, wo verfügbar, auf Volltextauszügen; eine vollständige Volltextlektüre aller 52 Quellen fand nicht statt. Zahlen aus Zusammenfassungen sind in aller Regel korrekt wiedergegeben, ihr methodischer Kontext — Stichprobe, Messzeitraum, Einschränkungen der Autoren — ist es nicht notwendig.

Zweitens ist die Recherche keine systematische Literaturübersicht nach PRISMA: Es gab kein präregistriertes Protokoll, keine doppelte unabhängige Sichtung und keine Bewertung des Verzerrungsrisikos. Der Bericht erhebt daher den Anspruch einer strukturierten, nachvollziehbar dokumentierten Recherche, nicht den eines systematischen Reviews.

Drittens ist ein Publikationsbias zugunsten positiver Wirkungsbefunde anzunehmen. Dem wurde durch gezielte Suche nach Gegenbefunden begegnet, nicht durch statistische Korrektur.

Warum diese Offenlegung Teil der Aussage ist. Der Bericht argumentiert, dass Nachweisbarkeit die knappe Ressource ist. Eine Arbeit, die das behauptet und zugleich die eigene Beweislage unscharf lässt, widerlegt sich selbst. Die Einstufung der Quellen ist deshalb kein Anhang, sondern Bestandteil der Argumentation.

3 Die dokumentierte Hauptbarriere: die Verifikationslücke

3.1 Reifegrade: Fähigkeit vorhanden, Einsatz blockiert

Die derzeit aussagekräftigste Bestandsaufnahme zum industriellen Einsatz agentischer KI beruht auf sechzehn Interviews in zwölf Unternehmen unterschiedlicher Größe und Branche, ausgewertet entlang eines sechsstufigen Reifemodells. Das Ergebnis ist deutlich: sieben Unternehmen auf Stufe 1 (KI-Assistenten), vier auf Stufe 2 (KI-Kompensatoren), eines auf Stufe 3 (Mehr-Agenten-Orchestrierung). Die fortgeschrittensten Anwender sind große und sicherheitsregulierte Organisationen (Apostolou et al., 2026a).




Abbildung 2: Reifegrade agentischer KI in zwölf Industrieunternehmen. Eigene Darstellung nach Apostolou et al. (2026a). Die oberen drei Stufen des Modells wurden in der Stichprobe von keinem Unternehmen erreicht.

Entscheidend ist die Begründung, die die Autoren für diese Verteilung geben. Vier Unternehmen verfügten über experimentell nachgewiesene Fähigkeiten höherer Stufen, konnten sie aber nicht in Produktionsabläufe integrieren, weil geeignete Verifikationsmechanismen für die Ausgabe fehlten. Die Autoren bezeichnen dies als *capability-deployment verification gap* und nennen vier wiederkehrende Barrieren: Grenzen des Kontextfensters, Schwächen bei proprietären Sprachen und Protokollen, die Unvereinbarkeit von Nichtdeterminismus mit Qualifizierungsstandards sowie Bedenken zur Datenvertraulichkeit (Apostolou et al., 2026a).

3.2 Human-in-the-Loop als Notlösung, nicht als Prozessdesign

Die gleiche Studie hält fest, dass der Mensch in der Schleife als *einzig* vertrauenswürdiger Verifikationsmechanismus verbleibt. Das ist keine Gestaltungsentscheidung, sondern ein Rückfall: Wo kein Prozess prüft, prüft eine Person — und wird damit zum Engpass. Ein systematisches Review über 92 Primärstudien bestätigt die Kehrseite: Die Überprüfbarkeit der Ausgabe ist der wichtigste Ermöglicher agentischer Adoption. Späte Phasen des Lebenszyklus, deren Ergebnisse durch ausführbares Feedback objektiv bewertbar sind, weisen die höchste Reife und industrielle Präsenz auf, während frühe Phasen fast ausschließlich akademische Machbarkeitsnachweise bleiben (Apostolou et al., 2026b).

Dass die Verifikationslast real und nicht bloß gefühlt ist, zeigt eine Befragung von 415 Praktikern entlang des SPACE-Rahmens: Schnellere Aufgabenerledigung und höheres Ausgabevolumen werden durch gestiegene Review-Last und anhaltende kognitive Belastung bei der Überprüfung aufgewogen; die Autoren sprechen von möglicherweise *scheinbaren* Produktivitätsgewinnen (Afroz et al., 2025).

3.3 Was Adoption tatsächlich treibt

Für die Leitfrage dieses Berichts ist ein weiterer Befund zentral. Eine Untersuchung mit 183 Software-Ingenieuren, ausgewertet mittels Strukturgleichungsmodellierung, findet, dass in der gegenwärtigen Phase vor allem die *Kompatibilität der KI-Werkzeuge mit bestehenden Entwicklungsabläufen* deren Übernahme bestimmt — während wahrgenommene Nützlichkeit, soziale Faktoren und persönliche Innovationsneigung schwächer ausfallen als von klassischen Technologieakzeptanzmodellen erwartet (Russo, 2023).

Übersetzt heißt das: KI setzt sich dort durch, wo sie in den vorhandenen Prozess passt — nicht dort, wo ein neuer Prozess um sie herum gebaut wird. Eine Mehrfachfallstudie in sieben europäischen Unternehmen stützt dies aus der Praxis; als zentrale Hürden nennen die Autoren unter anderem die Schwierigkeit, die positive Wirkung überhaupt zu messen, sowie fehlende etablierte Praktiken (Kemell et al., 2025). Für Deutschland kommt eine Studie mit 18 Interviews und 109 Befragten zu einem anschlussfähigen Ergebnis: Die begrenzte Kenntnis des Projektkontexts ist die größte Einzelbarriere (Felder et al., 2026). Drei deutsche Organisationen zeigen zudem ein systematisches Auseinanderfallen von Richtlinie und Praxis, weil regulatorischer Druck in Vorgaben übersetzt wird, ohne die tatsächliche Nutzung zu berücksichtigen (Neumann et al., 2026).

4 Die Gegenthese auf dem Prüfstand

4.1 Die Position

Die klarste Formulierung der Gegenposition findet sich bei Bandara et al. (2025). Traditionelle Methodiken wie Agile, Kanban und ShapeUp seien ursprünglich für menschenzentrierte Teams entworfen worden und in Umgebungen, in denen autonome KI-Agenten zu Planung, Codierung, Test und kontinuierlichem Lernen beitragen, *zunehmend unzureichend*. Zur Schließung dieser methodischen Lücke schlagen die Autoren mit *Agentsway* ein eigenes Rahmenwerk vor und beanspruchen, nach bestem Wissen die erste dezidiert für KI-Agenten-Teams entworfene Methodik vorzulegen.

Die Position ist ernst zu nehmen und wird nicht isoliert vertreten. Auch Ganesh (2026) fragt ausdrücklich, ob konventionelle agile Strukturen noch angemessen sind, wenn sich der Engpass von der Code-Erstellung zu Aufsicht, Verifikation und Constraint-Design verschiebt, und schlägt eine *guardrail-zentrierte* Entwicklung vor.

4.2 Behauptung oder Befund?

Zu unterscheiden ist, ob eine solche Aussage ein Untersuchungsergebnis ist oder eine Prämisse, die den eigenen Beitrag motiviert. Vier strukturelle Merkmale sprechen für Letzteres.

Merkmal	Einordnung
Die Aussage steht im zweiten Satz der Zusammenfassung	Motivationsposition — die übliche Stelle für eine ungeprüfte Prämisse
„...and <i>defining</i> measurable metrics for productivity and trust“	Metriken werden <i>definiert</i> , nicht <i>gemessen</i>
„...represents a <i>foundational step</i> toward...“	Konzeptueller Entwurf, keine validierte Methodik
„To the best of our knowledge, this is the <i>first</i> ...“	Positionierungsanspruch <i>ex silentio</i>

Tabelle 1: Strukturanalyse der Gegenthese nach Bandara et al. (2025). Es findet sich kein Hinweis darauf, dass die Kombination etablierter Methoden mit KI geprüft und als unzureichend befunden wurde.

4.3 Die fehlende Evidenzbasis

Den Ausschlag gibt eine unabhängige, begutachtete Quelle. Ein systematisches Review über 61 Studien zur agentischen Softwareentwicklung benennt im Volltext ausdrücklich als Wissenslücken, dass es *keine empirische Evidenz* zur langfristigen Wartbarkeit agentengenerierten Codes und *keine übergreifenden Leitlinien* zur Mensch-Agent-Zusammenarbeit gibt; ebenso fehlten standardisierte Bewertungsschemata und Erkenntnisse zu Koordinationsmechanismen (Otoum et al., 2026).

Die empirische Grundlage, auf der sich belegen ließe, dass etablierte Methoden mit KI nicht funktionieren, existiert in der Literatur nicht. Folglich kann keine der genannten Arbeiten sie in Anspruch nehmen.

Dasselbe gilt spiegelbildlich für die Rahmenwerke, die an ihre Stelle treten sollen. Koch et al. (2026) legen mit *Agile V* das ausgearbeitetste Gegenstück vor — unabhängige Verifikation und Audit-Artefakte als Nebenprodukt jedes Aufgabenzyklus, verpflichtende menschliche Freigabe-Gates — und belegen es mit einer Machbarkeitsstudie an einem Hardware-in-the-Loop-System von rund 500 Codezeilen, 8 Anforderungen und 54 Tests, bei der die Autoren ausdrücklich zur

unabhängigen Replikation einladen. Ein Einzelfall dieser Größe trägt eine Machbarkeitsaussage, keinen Methodenvergleich.

4.4 Zwischenfazit: die sparsamere Hypothese

Beide Lager arbeiten mit Entwürfen, nicht mit Vergleichsdaten. In dieser Lage ist die sparsamere Annahme vorzuziehen: Bevor neue Methodik erfunden wird, ist zu prüfen, ob die vorhandene trägt. Diese Wahl ist nicht bloß methodische Vorsicht — sie wird durch zwei Befunde gestützt. Erstens ist die Anpassung von Scrum an neue Kontexte keine Fehlanwendung, sondern dokumentierte Regelpraxis: Eine Grounded-Theory-Studie mit 45 Teilnehmern aus 30 Unternehmen schlägt vor, Abweichungen als *standardmäßig*, *notwendig*, *kontextbedingt* und *eindeutig abweichend* zu klassifizieren, statt sie pauschal als Missbrauch zu werten (Masood et al., 2021). Ein umfassendes Review systematisiert neun Anpassungsziele und sieben generische Anpassungsstrategien (Hron et al., 2021); ein systematisches Mapping über 50 Studien überführt die Varianten in ein Merkmalsmodell (Garcia et al., 2022). Zweitens verbessert die Emulation klassischer Prozessmodelle die Ergebnisse von Sprachmodellen messbar — und Scrum schneidet dabei am besten ab (Lin et al., 2024; ausgeführt in Abschnitt 6.2).

5 Der Negativbefund: wo KI heute nicht eingesetzt wird

5.1 Planung ja, Prüfung nein

Der aufschlussreichste Befund dieser Recherche ist kein positiver, sondern eine Leerstelle. Ein systematisches Review zur KI-Unterstützung in Scrum sichtete 305 Datensätze und schloss 18 Arbeiten ein. Es identifiziert sieben KI-Techniken, die auf sieben von neunzehn Scrum-Prozessen angewandt werden. Die Unterstützung konzentriert sich auf die Phase *Plan and Estimate*, insbesondere Aufwandsschätzung, Erstellung von User Stories und Releaseplanung. Für die Prozesse der Phasen *Implement* sowie *Review and Retrospect* wurden hingegen *keine* Anwendungen gefunden (Peras et al., 2026).

KI-Anwendungen je Scrum-Phase (n = 18 eingeschlossene Studien)




Abbildung 3: Verteilung der KI-Unterstützung entlang der Scrum-Prozesse. Eigene Darstellung nach Peras et al. (2026).

Der Befund wird von benachbarten Arbeiten gestützt. Eine Befragung von 344 erfahrenen Scrum-Praktikern nach der Kano-Methodik ordnet die achtzehn wichtigsten KI-Unterstützungsmerkmale vier Gruppen zu — Anforderungen, Entwicklung, Kommunikation, Prozess — und priorisiert sie nach Teamgröße und Rolle (Fujs et al., 2026). Ein systematisches Mapping zu KI und Teamarbeit in agilen Kontexten hält fest, dass Sprachmodelle dort bislang unterrepräsentiert sind und Rollen mit höherer Autonomie kaum untersucht werden (Kwok et al., 2025). Und eine Verbindung aus Literaturübersicht und Entwicklerbefragung findet den höchsten Nutzen in Entwurf, Implementierung, Test und Dokumentation, während frühe Phasen deutlich geringere Vorteile zeigen (Gurgul et al., 2026).

5.2 Warum die Kontrollpunkte unbesetzt bleiben

Die Leerstelle ist erklärbar. Wer KI einsetzt, um schneller zu produzieren, richtet sie auf die produzierenden Schritte. Die prüfenden Schritte erscheinen als Kosten, nicht als Hebel — und bleiben unangetastet. Genau dadurch entsteht das Missverhältnis, das die Produktivitätsforschung misst: Die Ausgabemenge steigt, die Prüfkapazität nicht.

Eine großangelegte Theoriebildung aus 38.709 Praktiker-Dokumenten, von denen 3.100 codiert wurden, formuliert den Zusammenhang als zentrale Aussage eines kausalen Modells mit 26 Konstrukten und 67 Beziehungen: Der Review sei der Kontrollpunkt, an dem sich die Wirkung eines Coding-Agents auf die Software entscheidet — und die KI lege das Vorzeichen dieser Wirkung nicht fest; das Team tue es, durch die Expertise seiner Menschen und *durch die Art, wie es den Review-Prozess strukturiert* (Agarwal et al., 2026b). Dieselbe Arbeit beobachtet, dass von Agenten eingereichte Pull Requests seltener geprüft, mehrfach schneller zusammengeführt und weniger diskutiert werden als menschliche.

Der Befund in einem Satz. Die Praxis rüstet die Produktion mit KI auf und lässt die Kontrolle unverändert — obwohl die Kontrolle der Ort ist, an dem sich entscheidet, ob die Produktion nützt oder schadet.

6 Das Mapping: vorhandene Kontrollen gegen KI-Fehlerklassen

6.1 Fehlerklassen KI-erzeugter Artefakte

Bevor Kontrollen zugeordnet werden können, ist zu klären, wogegen sie wirken sollen. Die Befundlage ist inzwischen belastbar und beruht auf großen Stichproben.

Fehlerklasse	Belegte Ausprägung	Quelle
Persistente technische Schulden	302.600 verifizierte KI-Commits aus 6.299 Repositorien; 484.366 Befunde, davon 89,3 % Code Smells; über 15 % der Commits jedes Assistenten führen mindestens einen Befund ein; 22,7 % überleben bis zur aktuellen Version	Liu et al. (2026)
Architekturverfall	Statische Analysewarnungen +18 %, kognitive Komplexität +39 % nach Einführung autonomer Agenten; Geschwindigkeitsgewinne verpuffen, Qualitätsrisiken bleiben	Agarwal et al. (2026a)
Sicherheitslücken	Über 500.000 Codebeispiele: KI-Code enthält mehr Schwachstellen hoher Kritikalität; Nutzer mit KI-Assistent schreiben signifikant unsichereren Code und halten ihn zugleich für sicherer	Cotroneo et al. (2025); Perry et al. (2022)
Kontextverschmutzung	Fehlerhafter auskommentierter Code im Kontext erhöht fehlerhafte Generierung auf bis zu 58,2 %; explizite Anweisung, ihn zu ignorieren, senkt dies um höchstens 21,8 %	Huang et al. (2025)
Evidenzverfall	KI erzeugt Entscheidungen schneller, als Teams sie validieren; kein verbreitetes Rahmenwerk trennt Vermutung von geprüftem Wissen; 20–25 % der Architekturentscheidungen hatten binnen zwei Monaten veraltete Evidenz	Gilda et al. (2026)
Kognitive und Intent-Schulden	Erosion des geteilten Verständnisses sowie fehlende Ziele, Randbedingungen und Begründungen; GenAI beschleunigt die Anhäufung und verdeckt zugleich ihre Wirkung	Storey (2026)
Volumengetriebener Qualitätsverlust	Umgekehrtes Volumen-Qualitäts-Gesetz; weder funktionale Korrektheit noch detailliertes Prompting mildern den strukturellen Verfall	Zhu et al. (2026)

Tabelle 2: Empirisch belegte Fehlerklassen KI-erzeugter Artefakte. Die Auswahl ist auf Arbeiten mit quantifizierten Ergebnissen beschränkt.

Bemerkenswert ist, dass diese Fehlerklassen den Fehlerklassen menschlicher Mitwirkender nicht fremd sind — sie sind lediglich schneller, plausibler formuliert und schwerer im Review zu erkennen. Ein kontrolliertes, präregistriertes Experiment mit 151 Teilnehmern, davon 95 % Berufstätige, fand in der zweiten Phase keine signifikanten Unterschiede in der Weiterentwickelbarkeit von Code, der zuvor mit oder ohne KI entstanden war (Borg et al., 2026). Die Fehlerklassen sind also real, aber nicht kategorisch neu — was der hier vertretenen Position entgegenkommt.

6.2 Scrum-Kontrollpunkte gegen KI-Fehlerklassen

Scrum hält für fehlbare Mitwirkende einen ausgearbeiteten Kontrollapparat vor. Ein systematisches Review sichtete 2.326 Arbeiten und extrahierte aus den einschlägigen 62 Done-Kriterien auf bis zu vier Ebenen — Story, Sprint, Release, Projekt — die unter anderem Verifikation und Validierung, Code-Inspektion, Testprozessqualität, regulatorische Konformität und Architekturentwurf abdecken (Silva et al., 2017). Dieser Apparat ist nicht für KI entworfen, aber er ist auf sie anwendbar.

Kontrollpunkt	Antwortet auf	Erforderliche Anpassung für KI
Definition of Ready	Intent-Schulden; unvollständige Spezifikation als Ursache halluzinierter Annahmen	Datenquelle benennen; Negativfall vorab benennen; Schwellenwerte setzen oder als offen deklarieren
Akzeptanzkriterien	Semantische Abweichung zwischen Anforderung und Ergebnis	Maschinell prüfbar formulieren — testbare Anforderungsbeschreibungen als Brücke (Zhang et al., 2024)
Definition of Done	Persistente technische Schulden; <i>design-only</i> -Artefakte, die als fertig deklariert werden	Jedes Kriterium an eine ausführbare Prüfung binden; Deklaration und Wirklichkeit gegeneinander prüfen
Review	Sicherheitslücken; Architekturverfall	Nicht durch KI ersetzen (siehe 6.4); als deterministische Prüfkette vor den menschlichen Review setzen
Retrospektive	Evidenzverfall; wiederkehrende Fehlermuster	Befundregister führen; Korrektur und Wächter im selben Vorgang
Increment	Volumengetriebener Qualitätsverlust	Nicht Menge, sondern Wertdichte messen (Tomaz et al., 2026)

Tabelle 3: Zuordnung etablierter Scrum-Kontrollpunkte zu den in Tabelle 2 belegten Fehlerklassen.

Dass diese Zuordnung mehr ist als eine Analogie, zeigt eine experimentelle Arbeit: Ein Rahmenwerk, das Wasserfall, testgetriebene Entwicklung und Scrum durch Mehr-Agenten-Systeme emuliert, erreicht mit der Scrum-Variante die besten Ergebnisse — im Mittel rund 15 % über dem unstrukturierten Basismodell —, und die Autoren halten ausdrücklich fest, dass gerade die Aktivitäten *Entwurf* und *Code-Review* die Ausnahmebehandlung verbesserten und Code Smells reduzierten (Lin et al., 2024). Prozessstruktur wirkt also messbar auf die Qualität der Ausgabe.

Sie ist allerdings nicht kostenlos. Eine Folgeuntersuchung zeigt, dass Prozessbeschränkungen das Fehlerprofil verschieben statt es nur zu verkleinern: Wasserfallartige Zusammenarbeit erzeugt saubereren, wartbareren Code, senkt aber bei zwei von drei geprüften Modellen die funktionale Korrektheit deutlich; strukturelle Mängel nehmen ab, semantische und Validierungsfehler nehmen zu (Shafin et al., 2025). Wer Prozess einzieht, muss ihn folglich messen — nicht bloß einführen.

6.3 TOGAF ADM: Entscheidungshoheit je Phase

Auf Architekturebene liegt die Evidenz dünner, weist aber in dieselbe Richtung. Für die Vorbereitungsphase des ADM ist die Wirkung am besten belegt: Eine empirische Bewertung GPT-4-generierter Artefakte durch drei zertifizierte Enterprise-Architekten anhand eines an ISO/IEC 25010 orientierten Instruments ergab eine wahrgenommene Qualität von 4,26 von 5,0 ($\alpha = 0,86$) und Effizienzgewinne von bis zu 97 % gegenüber manueller Erstellung — bei kontextuellem Verständnis als wesentlicher Schwäche. Die Autoren ziehen daraus ausdrücklich den Schluss, Sprachmodelle seien *Beschleuniger, nicht Ersatz* (Syahalam et al., 2025). Eine parallele Arbeit berichtet bis zu 80 % schnellere Erstellung und bestätigt die Notwendigkeit menschlicher Kontextaufsicht (Handoko et al., 2025).

ADM-Phase	Entscheidung	Rolle der KI — belegt
Preliminary	Mensch setzt Prinzipien	Artefaktentwurf; 80–97 % Zeitgewinn (Handoko et al., 2025; Syahalam et al., 2025)
A — Vision	Mensch allein	Formulierungshilfe; Zieldefinition bleibt menschlich
B/C — Business, Information Systems	Mensch entscheidet fachlich	Analyse und Dokumentation (Fitriani et al., 2023)
D — Technology	Geteilt	Exploration des Entwurfsraums; Mensch setzt Zielfunktion und Ausgangsentwurf, Saatqualität begrenzt das Ergebnis (Blasberg et al., 2026)
E — Opportunities & Solutions	Mensch entscheidet	Optionen und Bewertung; Verantwortungsverteilung nach dem <i>Dreieck der Entwurfsverantwortung</i> (Gomez et al., 2025)
F — Migration Planning	Mensch priorisiert	Belegte Forschungslücke — keine Arbeit zu KI-gestützter Roadmap-Führung im Einzelbetrieb
G — Implementation Governance	Prozess entscheidet	Regelwerke und Prozessmodelle als Architekturbestandteil statt externes Monitoring (Rombach et al., 2026)
H — Change Management	Mensch verantwortet	Entscheidungsregister mit Begründung und Rückverfolgbarkeit; 30 % kürzere Lösungszeit, Transparenz > 4,6/5 (Gacitúa et al., 2026)

Tabelle 4: Entscheidungshoheit und belegte KI-Beteiligung je ADM-Phase. Einschränkend ist anzumerken, dass eine Fallstudie den praktischen Wert TOGAF-spezifischer Empfehlungen grundsätzlich in Frage stellt (Kotusev, 2018) — das Rahmenwerk dient hier als Ordnungsraster, nicht als Geltungsanspruch.

6.4 Die Zirkularitätsgrenze: warum KI den Review nicht übernehmen darf

Die naheliegende Antwort auf steigende Prüflast — KI prüft KI — ist strukturell fehlerhaft. Ohne externe, ausführbare Referenz argumentieren erzeugendes und prüfendes Modell aus demselben Artefakt, teilen dieselbe Trainingsverteilung und zeigen korrelierte Fehler; der Review prüft den Code gegen sich selbst, nicht gegen die Absicht (Zietsman, 2026). Daraus folgt eine Architektur: zuerst die Spezifikation, dann die deterministische Verifikationskette, und KI-Review nur für den strukturellen Rest.

Dieselbe Logik findet sich unabhängig auf anderen Ebenen wieder: als testgetriebene Entwicklung, deren Prinzipien nicht als Hilfsmittel, sondern als *erzwingbare Prozessbeschränkungen* formalisiert werden, mit strikter Trennung zwischen Modellvorschlag und deterministischer Entscheidungsinstanz (Hasanli et al., 2026); und als *compliance-by-construction*, bei der Regularien, typisierte Prozessmodelle und Konformitätsbedingungen zu Architekturbestandteilen werden, statt als nachgelagerte Überwachung zu wirken (Rombach et al., 2026).

6.5 Der Sonderfall Solo: wenn Autor und Prüfer dieselbe Person sind

Alle bislang genannten Rahmenwerke setzen Teams voraus. Ihre menschlichen Freigabe-Gates werden von *anderen* Menschen bedient. Damit bleibt eine Konstellation unbehandelt, die praktisch zunehmend häufig ist: eine Person plus KI.

Die Solo-Forschung existiert, ist aber älter und ohne KI-Bezug. *Scrum Solo* formalisiert ein Vorgehen für Einzelentwickler und verweist darauf, dass rund 60 % der etablierten Softwareunternehmen einer nationalen Erhebung mit einem einzigen Entwickler begannen, ohne formalen Prozess (Pagotto et al., 2016). *SCRUM-For-One* überträgt Planung, Daily und Retrospektive auf die Einzelperson (Towhidnejad et al., 2025). Eine Arbeit zu einer leichtgewichtigen Solo-Methodik mit integrierten Sicherheitspraktiken hält ausdrücklich fest, dass Forschung zu Qualität und Sicherheit üblicherweise Teams adressiert — *auf Kosten einzelner Entwickler* (Moyo & Mnkandla, 2020).


Die offene Stelle. Im Einzelbetrieb kann das Vier-Augen-Prinzip nicht besetzt werden. Eine Person schreibt Anforderung, Umsetzung, Test und Prüfung. Daraus folgt die Kernanforderung dieses Berichts: Was im Team eine zweite Person leistet, muss im Solo-Betrieb eine *maschinell erzwungene, deterministische Prüfung* leisten — und diese Prüfung muss selbst überprüfbar sein. Genau das ist die Funktion einer Beweisstufen-Achse (Kapitel 9.3).

7 Business Case: Nutzen, Kosten, Compliance-Hebel

7.1 Produktivität: belegt, aber kontextabhängig

Die Wirkungsbefunde sind stark, aber nicht einheitlich. Drei randomisierte Feldexperimente bei Microsoft, Accenture und einem Fortune-100-Unternehmen mit zusammen 4.867 Entwicklern ergeben eine Steigerung abgeschlossener Aufgaben um 26,1 % (Standardfehler 10,3); weniger erfahrene Entwickler zeigten höhere Übernahmeraten und größere Zugewinne (Cui et al., 2026). Ein kontrolliertes Experiment zu einer abgegrenzten Programmieraufgabe misst 55,8 % kürzere Bearbeitungszeit (Peng et al., 2023). Außerhalb der Softwareentwicklung senkte ein präregistriertes Experiment mit 453 Fachkräften die Bearbeitungszeit um 40 % bei um 18 % höherer Ergebnisqualität (Noy & Zhang, 2023).

Gemessene Verbesserung in Prozent (unterschiedliche Zielgrößen — siehe Bildunterschrift)



Einordnung: Metaanalyse über 23 Studien ergibt $g = 0,33$ [0,09; 0,58] — moderat, im Unternehmen kleiner als im Labor (Maier et al., 2026).

Abbildung 4: Produktivitätsbefunde im Vergleich. Die Zielgrößen sind nicht identisch — Peng misst Bearbeitungszeit, Cui abgeschlossene Aufgaben, Kumar die Durchlaufzeit von Pull-Request-Reviews, Borg die Bearbeitungszeit im Median. Die Darstellung zeigt Größenordnungen, keinen direkten Vergleich.


Die Einordnung liefert eine Metaanalyse über 23 Studien mit 27 Effektstärken: Der Effekt auf die Produktivität ist statistisch signifikant, aber nur moderat ($g = 0,33$; 95 %-KI [0,09; 0,58]), mit erheblicher Heterogenität — und er fällt in kontrollierten Laborsituationen deutlich größer aus als in Open-Source- und Unternehmenskontexten. Auf das Lernen wurde kein signifikanter Effekt gefunden (Maier et al., 2026). Eine zweijährige Beobachtung in einer großen öffentlichen Organisation mit 26.317 Commits fand nach Einführung des Werkzeugs keine statistisch signifikante Veränderung der Commit-Aktivität — bei gleichzeitig positiver subjektiver Wahrnehmung (Stray et al., 2025).

Eine Längsschnittstudie über rund 13 Monate in drei agilen Teams löst diesen scheinbaren Widerspruch plausibel auf: Leistung und wahrgenommene Effizienz steigen deutlich, während die Aktivität flach bleibt. Die Autoren schließen daraus, GenAI erhöhe die *Wertdichte* der Arbeit, nicht deren Volumen (Tomaz et al., 2026).

7.2 Die Gegenrechnung

Den Gewinnen stehen belegte Kosten gegenüber, die in Wirtschaftlichkeitsrechnungen regelmäßig fehlen.

Belegte Gegenposten



Quellen: Agarwal et al. (2026a); Liu et al. (2026); Xu et al. (2025)

Abbildung 5: Kostenseite der KI-gestützten Entwicklung. Die Werte stammen aus unterschiedlichen Stichproben und sind nicht additiv zu lesen.

Besonders aufschlussreich ist die Verteilung der Last. Nach Einführung eines Assistenten prüfen Kernentwickler 6,5 % mehr fremden Code, während ihre eigene Produktivität um 19 % fällt; die Produktivitätsgewinne entstehen überwiegend bei weniger erfahrenen Beitragenden (Xu et al., 2025). Ein Befund aus *Science* weist in eine ähnliche Richtung: Erfahrene Entwickler profitieren und dehnen ihre Tätigkeit auf neue Bereiche aus, während Berufseinsteiger keinen signifikanten Vorteil zeigen (Daniotti et al., 2025). Die beiden Befunde widersprechen sich in der Frage, wer profitiert — was für sich genommen ein Ergebnis ist: Die Wirkung ist kontextabhängig, nicht universell.

7.3 Augmentation schlägt Substitution

Am deutlichsten wird der Unterschied am Kapitalmarkt. Eine Untersuchung, die 18.796 Tätigkeitsbeschreibungen nach Augmentations- und Substitutionspotenzial bewertet und die Veröffentlichung von ChatGPT als Informationsschock in einem Differenz-von-Differenzen-Ansatz nutzt, findet eine scharfe Asymmetrie: Augmentationsexposition geht mit signifikant besserer operativer Profitabilität, höherer Arbeitsproduktivität und positiven risikoadjustierten Renditen einher — ein Long-Short-Portfolio erzielt ein Fünf-Faktoren-Alpha von 97 Basispunkten pro Monat. Substitutionsexposition zeigt dagegen keine Renditewirkung und negative Effekte auf die Profitabilität (Aghbabali et al., 2026). Erwartungsseitig veranschlagen Führungskräfte in einer breit angelegten Befragung eine Rendite von rund 10 % auf GenAI-Investitionen und erwarten den größten Wertbeitrag aus Innovation statt aus fragmentierten Einzelanwendungen (Marshall et al., 2024).

Managementrelevanz. Der Kapitalmarkt honoriert nicht den Ersatz von Menschen durch KI, sondern deren Verstärkung. Das deckt sich mit dem Prozessargument dieses Berichts: Die KI tritt als zusätzlicher, fehlbarer Mitwirkender in einen bestehenden Kontrollrahmen ein — sie ersetzt weder den Mitwirkenden noch den Rahmen.

7.4 Der Compliance-Hebel

Für regulierte Branchen ist der wirtschaftliche Fall am klarsten. Eine Untersuchung der 36 größten Prüfungsgesellschaften auf Basis von über 310.000 Lebensläufen zeigt, dass eine Standardabweichung mehr KI-Investition mit 5,0 % geringerer Wahrscheinlichkeit einer Abschlusskorrektur, 0,9 % niedrigeren Prüfungsgebühren und einem um 3,6 % (nach drei Jahren)

beziehungsweise 7,1 % (nach vier Jahren) reduzierten Personalbestand einhergeht (Fedyk et al., 2022).

Compliance-Automatisierung: Zwölfmonatserprobung bei einer multinationalen Bank



Quelle: Sardana et al. (2024) · Fallstudien in Gesundheitswesen und Fintech, u. a. mit Bezug auf den EU AI Act

Abbildung 6: Wirkung agentischer Compliance-Automatisierung. Die Studie ist in einem Fachjournal ohne breite Rezeption erschienen; die Größenordnung ist als Einzelfallbefund zu lesen, nicht als gesicherter Branchenwert.

8 Die Rolle verschiebt sich

8.1 Vom Autor zum Auftraggeber und Prüfer

Wenn Code reichlich verfügbar wird, verschiebt sich der Wertbeitrag der Fachkraft. Eine strukturierte Synthese aus 48 begutachteten Publikationen formuliert es so, dass der dauerhafte Wert des Software-Ingenieurs zunehmend in der *Spezifikation von Absicht*, im *kritischen Urteil* und in der *verantwortbaren Aufsicht* liegt — nicht im Volumen des erzeugten Codes (Alenezi, 2026b). Zwei Expertenrunden in New York und Singapur kommen zu demselben Kernbefund: Verifikation und Validierung gewinnen in dem Maße an Bedeutung, in dem Agenten die Implementierung übernehmen (Kang et al., 2026).

8.2 Kompetenzprofil: was mehr, was weniger zählt

Kompetenz	Tendenz	Begründung und Beleg
Spezifikation von Absicht und Randbedingungen	steigt stark	Ausführbare Spezifikation ist die externe Referenz, ohne die Prüfung zirkulär wird (Zietsman, 2026; Alenezi, 2026a)
Verifikation und Validierung	steigt stark	Überprüfbarkeit ist der entscheidende Adoptionsermöglicher (Apostolou et al., 2026b; Kang et al., 2026)
Kritisches Urteil, Entscheidungskompetenz	steigt	Delphi-Studie mit 34 Fachleuten: kritisches Denken und Entscheidungsfähigkeit gewinnen an Bedeutung (Schöttl et al., 2026)
Orchestrierung mehrerer Agenten	neu	Kompetenzmodell mit neun Dimensionen, u. a. Agenten-Orchestrierung und Metakognition (Alenezi, 2026a)
Governance, Rechenschaft, Regulatorik	steigt	Eigene Kompetenzkategorie neben technischen und kognitiven Fähigkeiten (Alenezi, 2026b)
Domänen- und Kontextwissen	steigt	Fehlende Projektkontextkenntnis ist die größte Einzelbarriere der Praxis (Felder et al., 2026)
Syntaxsicherheit, Standardcode von Hand	sinkt	Über 70 % der Befragten halbieren die Zeit für Standardcode und Dokumentation (Gurgul et al., 2026)
Auswendige Kenntnis von Bibliotheks-APIs	sinkt	Verschiebung von Codeerstellung zu Spezifikationsqualität und Architekturdanken (Gurgul et al., 2026)

Tabelle 5: Verschiebung des Kompetenzprofils. „Sinkt“ bedeutet geringere Bedeutung im Tagesgeschäft, nicht Entbehrlichkeit — ohne Lesefähigkeit ist keine Prüfung möglich.

8.3 Tech-Stack des KI-gestützten Solo-Architekten

Aus der Kontrolllogik folgt der Werkzeugkasten. Er ist nicht auf Modellnutzung ausgerichtet, sondern auf deterministische Prüfbarkeit: Versionskontrolle mit erzwungenen Prüfschritten vor der Übernahme; eine Policy-Engine, die Regeln als Code ausführt; eine Continuous-Integration-Strecke, die den Negativfall nachweist und nicht nur den Erfolgsfall; ein manipulationsresistenter Nachweisspeicher; sowie Signatur- und Herkunftsnachweise, die eine Erzeugeridentität binden. Die Sprachmodell-Werkzeuge stehen in diesem Stapel nicht an erster, sondern an vorletzter Stelle — vor ihnen liegt die Prüfkette, nach ihnen die Aufzeichnung.

8.4 Das Risiko: Deskilling und Verantwortungsdiffusion

Die Verschiebung ist nicht kostenfrei. Eine Übersicht zu Kompetenzentwicklung an KI-Systemen hält Dekompetenzierung für ein häufiges Ergebnis, zeigt aber zugleich, dass dieselben Systeme

neue Fähigkeiten erfordern können — abhängig davon, ob Beschäftigte Fähigkeiten im Formulieren, Bewerten und Überarbeiten der Ausgabe ausbilden und zeigen (Crowston et al., 2025). Eine Untersuchung mit 21 besonders fortgeschrittenen Entwicklern ordnet die nötigen Fähigkeiten vier Domänen zu und betont, dass beides gezielt entwickelt werden muss: die technische Tiefe und die überfachlichen Fähigkeiten (Kam et al., 2025). Für den Solo-Betrieb verschärft sich das Risiko, weil keine zweite Person die Erosion bemerkt — ein weiterer Grund, die Prüfung zu externalisieren, statt sie auf Urteilskraft zu gründen.

9 Instanziierung am laufenden Artefakt

9.1 Der Fall: GenAIOps Compliance Gates

Die vorgetragene Position wird an einem laufenden Artefakt erprobt: einer cloud-nativen Referenzarchitektur, die Pflichten aus der Verordnung (EU) 2024/1689 in automatisierte Qualitätsgatter der Auslieferungsstrecke überführt und jede Gate-Entscheidung als überprüfbaren Nachweis aufzeichnet. Der Stand umfasst 17 Gates, 14 abgeleitete Anforderungen und 55 Prüfungen, 19 Policies in Rego mit 196 Regeln, 215 Unit-Tests, 36 Integrationstests sowie 37 Integritätsprüfungen; die Nachweiskette wird je Lauf verifiziert und in der Continuous-Integration-Strecke schlüssellos signiert.

Das Artefakt ist zugleich die Probe aufs Exempel für die Solo-Frage aus Abschnitt 6.5: Es entstand im Einzelbetrieb, mit KI als ausführendem Mitwirkenden, und es trägt einen schriftlich fixierten Arbeitsvertrag zwischen Mensch und KI.

9.2 Die vier Ehrlichkeitsfelder: was die KI nie entscheidet

Die Arbeitsteilung ist explizit: Der Product Owner entscheidet *was* und *warum*, die KI entscheidet *wie*. Vier Felder sind davon ausgenommen und werden nie delegiert:

1. welcher Rechtsartikel welche Pflicht begründet;
2. ob eine Prüfung verpflichtend oder empfehlend ist;
3. die Einstufung der Beweisstufe;
4. ob etwas als *umgesetzt* oder als *nur entworfen* gilt.

Die Begründung ist keine Vorsichtsmaßnahme, sondern folgt aus der Fehlerstruktur: Eine KI schreibt plausibel. Ein als verpflichtend gesetztes Prüfkriterium sieht in jeder Änderungsansicht richtig aus, ein *umgesetzt* schließt eine Tabelle sauber ab, und eine höhere Beweisstufe liest sich stärker als eine niedrigere. Nichts davon fällt im Review auf, und nichts davon bringt einen Test zum Scheitern — es ist eine Zeichenkette. Genau hier trifft Deklaration auf Wirklichkeit, und genau hier ist maschinelle Plausibilität am gefährlichsten. Der Befund deckt sich mit der Forderung, epistemischen Status und zeitliche Gültigkeit von Architekturentscheidungen explizit zu führen und Vermutung von geprüftem Wissen zu trennen (Gilda et al., 2026).

9.3 Beweisstufen E-0 bis E-3: Nachweisgüte nach Fälschungskosten

Der zweite Baustein beantwortet die Frage, die der Automatisierungsgrad offenlässt. Ob eine Prüfung ohne Menschen läuft, sagt nichts darüber, wie schwer ihr Ergebnis zu fälschen ist. Jede Prüfung führt deshalb zusätzlich eine Beweisstufe.

Stufe	Was geprüft wird	Kosten der Fälschung
E-0	Ein Dokument, das jemand geschrieben hat — Manifest, Annotation	Textänderung
E-1	Ein erzeugtes und signiertes Artefakt; Signatur und Erzeugeridentität geprüft	Kompromittierung der CI-Identität
E-2	Der tatsächliche Zustand des laufenden Systems über dessen Schnittstelle	Manipulation des laufenden Systems
E-3	Eine Eigenschaft über Zeit — gemessen statt konfiguriert	Manipulation der Telemetrikette

Tabelle 6: Beweisstufen nach Fälschungskosten. Automatisierbarkeit und Beweiskraft sind orthogonale Achsen: Eine Prüfung mit menschlichem Anteil kann E-3 tragen, eine vollautomatische auf E-0 stehen.

Die Achse beantwortet die Solo-Frage aus 6.5 unmittelbar. Wo im Team eine zweite Person die Aussage eines Autors bestätigt, tritt im Einzelbetrieb die Frage an ihre Stelle, wie teuer es wäre, diese Aussage zu fälschen. Eine Pod-Annotation behauptet einen Zustand; sie beweist ihn nicht. Eine über die Laufzeit gemessene Eigenschaft lässt sich nicht durch eine Textänderung erzeugen. Damit wird die Prüfung vom Urteil einer Person auf eine Eigenschaft des Nachweises verlagert — und genau das ist im Einzelbetrieb der einzige gangbare Weg.

9.4 Abgrenzung und Innovationsgrad

Der Neuheitsanspruch ist nach der Verifikationssuche einzuschränken und zugleich zu präzisieren. Die Grundidee — Prozesskontrolle statt Prompt-Optimierung — wird 2026 mehrfach und unabhängig formuliert (Koch, 2026; Koch et al., 2026; Ganesh, 2026; Rombach et al., 2026; Hasanli et al., 2026). Der eigene Beitrag liegt nicht in dieser Idee, sondern in vier Punkten, die von keiner der genannten Arbeiten abgedeckt werden.

Beitrag	Abgrenzung
Ordnung nach Fälschungskosten	Die nächstliegende publizierte Achse unterscheidet Prüfungstyp und Prüfgegenstand und erklärt die Typdimension ausdrücklich für <i>nicht hierarchisch</i> (Buscemi et al., 2025). Koch et al. (2026) führen Evidenzbündel, ordnen sie aber nicht nach Fälschungsaufwand.
Der Einzelbetrieb	Sämtliche verglichenen Rahmenwerke setzen menschliche Freigabe durch <i>andere</i> Personen voraus. Die Solo-Literatur wiederum ist älter und ohne KI-Bezug (Pagotto et al., 2016; Moyo & Mnkandla, 2020; Towhidnejad et al., 2025).
Architekturebene statt Codeebene	Die verwandten Arbeiten verbleiben im Software-Lebenszyklus; die Übertragung auf TOGAF-ADM-Phasen ist nicht belegt — für Phase F ausdrücklich als Lücke ausgewiesen (Abschnitt 6.3).
Grad der Instanziierung	Die nächstliegenden Gegenstücke sind Entwürfe mit Machbarkeitsnachweis an rund 500 Codezeilen (Koch et al., 2026) oder ohne Validierung (Bandara et al., 2025; Ganesh, 2026). Hier liegen ausführbare Regeln, Tests und eine je Lauf verifizierte Nachweiskette vor.

Tabelle 7: Abgrenzung gegenüber verwandten Arbeiten. Die stärkste Karte ist nicht der Neuheitsanspruch, sondern der Instanziierungsgrad.

10 Limitationen und offene Punkte

10.1 Grenzen der Evidenzbasis

Von 67 Quellen sind 24 Preprints ohne abgeschlossene Begutachtung — rund ein Drittel —, darunter mehrere der thematisch nächstliegenden Arbeiten aus 2026 mit geringer Zitationszahl. Die Aussagen zur Gegenposition und zum Innovationsgrad beruhen teilweise auf Strukturanalysen von Zusammenfassungen, nicht auf Volltextlektüre. Die Einstufung der Gegenthese als unbelegt ist insoweit begründet, aber vorläufig: Sie stützt sich auf die Struktur der Publikation sowie auf die von Otoum et al. (2026) ausgewiesene Lücke, nicht auf eine vollständige Prüfung des Originaltexts.

10.2 Was der Einzelfall nicht belegt

Das in Kapitel 9 beschriebene Artefakt zeigt, dass der Ansatz umsetzbar ist. Es zeigt nicht, dass er wirksamer ist als Alternativen — dafür fehlt ein Vergleich. Es zeigt ebenso wenig, dass das gewählte Kontrollset das richtige ist: Die Gates prüfen, ob die Spezifikation erfüllt ist; ob der Gate-Satz das regulatorische Risiko tatsächlich senkt, prüft nichts. Dies ist der gewichtigste offene Punkt des Artefakts und wird dort als solcher geführt.

10.3 Bestätigte Forschungslücke

Die Recherche bestätigt eine Lücke, die über den Einzelfall hinausweist: Zur KI-gestützten Führung einer mehrmonatigen Architektur-Roadmap im Einzelbetrieb — ADM-Phase F — liegt keine Arbeit vor. Die umfangreiche Literatur zur Priorisierung technischer Schulden adressiert Teams und lässt den KI-Bezug offen (Lenarduzzi et al., 2021; Stochel et al., 2023). Hier besteht ein eigenständiger Forschungsbedarf.

11 Fazit und Handlungsempfehlungen

Die Leitfrage lässt sich beantworten. Es gibt keine belastbare Evidenz dafür, dass etablierte Vorgehensmodelle für den KI-Einsatz ersetzt werden müssten. Die Behauptung wird erhoben, nicht geprüft, und das einschlägige systematische Review weist die dafür nötige Evidenzbasis ausdrücklich als fehlend aus. Umgekehrt spricht die Befundlage dafür, dass Prozessstruktur die Qualität KI-erzeugter Ergebnisse messbar verbessert, dass Kompatibilität mit bestehenden Abläufen der dominierende Adoptionstreiber ist und dass die entscheidende Engstelle — die Verifikation — genau dort liegt, wo die vorhandenen Modelle ihre Kontrollpunkte haben und die Praxis sie bislang unbesetzt lässt.

Nr.	Empfehlung
1	Kontrollpunkte instrumentieren, nicht Methodik ersetzen. Definition of Ready, Akzeptanzkriterien und Definition of Done an ausführbare Prüfungen binden, bevor in neue Rahmenwerke investiert wird.
2	Den Negativfall prüfen. Ein grüner Durchlauf beweist nur, dass nichts blockiert hat. Erst der Nachweis, dass eine Kontrolle rot wird, wenn der Zustand nicht stimmt, macht sie zur Kontrolle.
3	Beweisgüte getrennt vom Automatisierungsgrad führen. Für jede Prüfung ausweisen, wie teuer es wäre, ihr Ergebnis zu fälschen.
4	Kein KI-Review von KI-Ausgabe ohne externe Referenz. Zuerst Spezifikation, dann deterministische Prüfkette, KI-Review nur für den verbleibenden strukturellen Rest.
5	Entscheidungen mit epistemischem Status führen. Vermutung, geprüfte Annahme und gemessene Eigenschaft unterscheidbar halten und mit Gültigkeitsdauer versehen.

-
- 6 **Wertdichte messen, nicht Ausgabemenge.** Mehrdimensionale Rahmen verwenden; Volumenkennzahlen allein verdecken die Verlagerung der Last in den Review.
-
- 7 **Auf Augmentation setzen.** Der finanzielle Befund trennt scharf: Verstärkung schafft Wert, Ersetzung nicht.
-

Schlussatz. Die Frage ist nicht, ob KI neue Methoden braucht. Die Frage ist, ob wir bereit sind, die vorhandenen so ernst zu nehmen, dass sie auch einen Mitwirkenden kontrollieren, der schneller schreibt als wir lesen können.

Quellenverzeichnis

PR begutachtet (Journal oder Konferenz) · **PP** Preprint ohne abgeschlossene Begutachtung. Die Kennzeichnung bezieht sich auf den Stand der Recherche im September 2026.

- Afroz, S. et al. (2025). The Fast and Spurious: Developer Productivity with GenAI. *Proceedings of the 34th ACM International Conference on the Foundations of Software Engineering*. DOI: 10.1145/3803437.3806710 **PR**
- Agarwal, S. et al. (2026a). AI IDEs or Autonomous Agents? Measuring the Impact of Coding Agents on Software Development. *Proceedings of the 23rd International Conference on Mining Software Repositories*. DOI: 10.1145/3793302.3793589 **PR**
- Agarwal, S. et al. (2026b). 3100 Opinions on Code Review in an AI World: Building Causal Theory from Practitioner Discourse. *arXiv*. DOI: 10.48550/arxiv.2607.07980 **PP**
- Aghbabali, T. et al. (2026). Augmentation Versus Substitution: Asymmetric Effects of Generative AI on Firm Performance and Share Prices. *SSRN Electronic Journal*. DOI: 10.2139/ssrn.6300040 **PP**
- Alenezi, M. (2026a). The Rise of AI-Native Software Engineering: Implications for Practice, Education, and the Future Workforce. *arXiv*. DOI: 10.48550/arxiv.2606.12986 **PP**
- Alenezi, M. (2026b). Human-AI Collaboration and the Transformation of Software Engineering Work. *arXiv*. DOI: 10.48550/arxiv.2606.03394 **PP**
- Apostolou, S. A. et al. (2026a). Agentic AI in Industry: Adoption Level and Deployment Barriers. *arXiv*. DOI: 10.48550/arxiv.2605.14675 **PP**
- Apostolou, S. A. et al. (2026b). Assistance to Autonomy: A Systematic Literature Review of Agentic AI across the Software Development Life Cycle. *arXiv*. DOI: 10.48550/arxiv.2605.15245 **PP**
- Bandara, E. et al. (2025). Agentsway — Software Development Methodology for AI Agents-based Teams. *arXiv*. DOI: 10.48550/arxiv.2510.23664 **PP**
- Blasberg, A. et al. (2026). Agentic Architect: An Agentic AI Framework for Architecture Design Exploration and Optimization. *arXiv*. DOI: 10.48550/arxiv.2604.25083 **PP**
- Borg, M. et al. (2026). Echoes of AI: Investigating the downstream effects of AI assistants on software maintainability. *Empirical Software Engineering*. DOI: 10.1007/s10664-026-10889-1 **PR**
- Buscemi, A. et al. (2025). Assessing High-Risk AI Systems under the EU AI Act: From Legal Requirements to Technical Verification. *arXiv* 2512.13907 **PP**
- Cotroneo, D. et al. (2025). Human-Written vs. AI-Generated Code: A Large-Scale Study of Defects, Vulnerabilities, and Complexity. *IEEE 36th International Symposium on Software Reliability Engineering (ISSRE)*. DOI: 10.1109/issre66568.2025.00035 **PR**
- Crowston, K. et al. (2025). Deskilling and upskilling with AI systems. *Information Research*. DOI: 10.47989/ir30iconf47143 **PR**
- Cui, K. et al. (2026). The Effects of Generative AI on High-Skilled Work: Evidence from Three Field Experiments with Software Developers. *Management Science*. DOI: 10.1287/mnsc.2025.00535 **PR**
- Daniotti, S. et al. (2025). Who is using AI to code? Global diffusion and impact of generative AI. *Science*. DOI: 10.48550/arxiv.2506.08945 **PR**
- Fedyk, A. et al. (2022). Is artificial intelligence improving the audit process? *Review of Accounting Studies*. DOI: 10.1007/s11142-022-09697-x **PR**
- Felder, L. et al. (2026). Adoption of Generative Artificial Intelligence in the German Software Engineering Industry: An Empirical Study. *Proceedings of the 34th ACM International Conference on the Foundations of Software Engineering*. DOI: 10.1145/3803437.3805207 **PR**
- Fitriani, L. et al. (2023). TOGAF-based Enterprise Architecture Framework for Utilizing Artificial Intelligence. *International Conference on Computer, Control, Informatics and its Applications*. DOI: 10.1109/ic3ina60834.2023.10285801 **PR**
- Fujs, D. et al. (2026). Key AI features to support scrum software engineering: practitioners' perspective. *Empirical Software Engineering*. DOI: 10.1007/s10664-026-10876-6 **PR**
- Gacitúa, R. et al. (2026). Explainability in Software Architectural Decisions: The ADR-E Framework and Empirical Evaluation. *IEEE Access*. DOI: 10.1109/access.2025.3648573 **PR**
- Ganesh, A. (2026). From Sprint Planning to Guardrail Engineering: Rethinking Software Development in the Age of AI Agents. *International Journal of Emerging Trends in Computer Science and Information Technology*. DOI: 10.63282/3050-9246.ijetcsit-v7i2p119 **PR**
- Garcia, L. A. et al. (2022). Tailoring the Scrum framework for software development: Literature mapping and feature-based support. *Information and Software Technology*. DOI: 10.1016/j.infsof.2021.106814 **PR**

- Gilda, S. et al. (2026). AI-Assisted Engineering Should Track the Epistemic Status and Temporal Validity of Architectural Decisions. *arXiv*. DOI: 10.48550/arxiv.2601.21116 **PP**
- Gomez, A. et al. (2025). A team of three: the role of generative AI in the development of design automation systems for complex products. *Proceedings of the Design Society*. DOI: 10.1017/pds.2025.10045 **PR**
- Gurgul, V. et al. (2026). The State of Generative AI in Software Development: Insights from Literature and a Developer Survey. *arXiv*. DOI: 10.48550/arxiv.2603.16975 **PP**
- Handoko et al. (2025). LLM-Assisted TOGAF Preliminary Phase for Student Digital Twins. *13th International Conference on Orange Technology (ICOT)*. DOI: 10.1109/icot68409.2025.11425374 **PR**
- Hasanli, T. et al. (2026). TDD Governance for Multi-Agent Code Generation via Prompt Engineering. *arXiv*. DOI: 10.48550/arxiv.2604.26615 **PP**
- Hron, M. et al. (2021). Why and how is Scrum being adapted in practice: A systematic review. *Journal of Systems and Software*. DOI: 10.1016/j.jss.2021.111110 **PR**
- Huang, Y. et al. (2025). Comment Traps: How Defective Commented-Out Code Augment Defects in AI-Assisted Code Generation. *Proceedings of the ACM on Software Engineering*. DOI: 10.1145/3797102 **PR**
- Kam, M. et al. (2025). What do professional software developers need to know to succeed in an age of Artificial Intelligence? *Proceedings of the 33rd ACM International Conference on the Foundations of Software Engineering*. DOI: 10.1145/3696630.3727251 **PR**
- Kang, S. et al. (2026). Skills for the future software profession: beyond agentic AI! *arXiv*. DOI: 10.48550/arxiv.2606.21894 **PP**
- Kemell, K.-K. et al. (2025). Still just personal assistants? — A multiple case study of generative AI adoption in software organizations. *Information and Software Technology*. DOI: 10.1016/j.infsof.2025.107805 **PR**
- Koch, C. (2026). Agentic Agile-V: From Vibe Coding to Verified Engineering in Software and Hardware Development. *arXiv*. DOI: 10.48550/arxiv.2605.20456 **PP**
- Koch, C. et al. (2026). Agile V: A Compliance-Ready Framework for AI-Augmented Engineering — From Concept to Audit-Ready Delivery. *arXiv*. DOI: 10.48550/arxiv.2602.20684 **PP**
- Kotusev, S. (2018). TOGAF-based Enterprise Architecture Practice: An Exploratory Case Study. *Communications of the Association for Information Systems*. DOI: 10.17705/1cais.04320 **PR**
- Kwok, Y. et al. (2025). AI and Teamwork in Agile Software Development: A Systematic Mapping Study. DOI: 10.1007/978-3-032-05799-0_4 **PR**
- Lenarduzzi, V. et al. (2021). A systematic literature review on Technical Debt prioritization: Strategies, processes, factors, and tools. *Journal of Systems and Software*. DOI: 10.1016/j.jss.2020.110827 **PR**
- Lin, F. et al. (2024). SOEN-101: Code Generation by Emulating Software Process Models Using Large Language Model Agents. *IEEE/ACM 47th International Conference on Software Engineering (ICSE)*. DOI: 10.1109/icse55347.2025.00140 **PR**
- Liu, Y. et al. (2026). Debt Behind the AI Boom: A Large-Scale Empirical Study of AI-Generated Code in the Wild. *arXiv*. DOI: 10.48550/arxiv.2603.28592 **PP**
- Maier, S. et al. (2026). A meta-analysis of the effect of generative AI on productivity and learning in programming. *arXiv*. DOI: 10.48550/arxiv.2605.04779 **PP**
- Marshall, A. et al. (2024). How generative AI will drive enterprise innovation. *Strategy & Leadership*. DOI: 10.1108/sl-12-2023-0126 **PR**
- Masood, Z. et al. (2021). Real World Scrum — A Grounded Theory of Variations in Practice. *IEEE Transactions on Software Engineering*. DOI: 10.1109/tse.2020.3025317 **PR**
- Moyo, S. & Mnkandla, E. (2020). A Novel Lightweight Solo Software Development Methodology With Optimum Security Practices. *IEEE Access*. DOI: 10.1109/access.2020.2971000 **PR**
- Neumann, M. et al. (2026). Between Policy and Practice: GenAI Adoption in Agile Software Development Teams. *arXiv*. DOI: 10.48550/arxiv.2601.07051 **PP**
- Noy, S. & Zhang, W. (2023). Experimental evidence on the productivity effects of generative artificial intelligence. *Science*. DOI: 10.1126/science.adh2586 **PR**
- Otoum, N. A. et al. (2026). Methods and Techniques of Agentic Software Engineering: A Systematic Literature Review. *IEEE Access*. DOI: 10.1109/access.2026.3652325 **PR**
- Pagotto, T. et al. (2016). Scrum solo: Software process for individual development. *11th Iberian Conference on Information Systems and Technologies (CISTI)*. DOI: 10.1109/cisti.2016.7521555 **PR**
- Peng, S. et al. (2023). The Impact of AI on Developer Productivity: Evidence from GitHub Copilot. *arXiv*. DOI: 10.48550/arxiv.2302.06590 **PP**
- Peras, D. et al. (2026). AI-Enhanced Scrum: A Literature Review on the Impact of Artificial Intelligence on Scrum Processes. *Informatica*. DOI: 10.31449/inf.v50i12.10498 **PR**

- Perry, N. et al. (2022). Do Users Write More Insecure Code with AI Assistants? *Proceedings of the 2023 ACM SIGSAC Conference on Computer and Communications Security*. DOI: 10.1145/3576915.3623157 **PR**
- Rombach, A. et al. (2026). Neuro-Symbolic Agents for Regulated Process Automation: Challenges and Research Agenda. *arXiv*. DOI: 10.48550/arxiv.2606.13405 **PP**
- Russo, D. (2023). Navigating the Complexity of Generative AI Adoption in Software Engineering. *ACM Transactions on Software Engineering and Methodology*. DOI: 10.1145/3652154 **PR**
- Sardana, A. et al. (2024). Compliance-as-Code 2.0: Orchestrating Regulatory Operations with Agentic AI. *Journal of Artificial Intelligence General Science*. DOI: 10.60087/jaigs.v5i1.366 **PR**
- Schöttl, F. et al. (2026). Basics for the Future — Basic Competency Shifts in the AI Era. *Business & Information Systems Engineering*. DOI: 10.1007/s12599-026-01001-4 **PR**
- Shafin, W. I. et al. (2025). Evaluating Software Process Models for Multi-Agent Class-Level Code Generation. *arXiv*. DOI: 10.48550/arxiv.2511.09794 **PP**
- Silva, A. et al. (2017). A systematic review on the use of Definition of Done on agile software development projects. *Proceedings of the 21st International Conference on Evaluation and Assessment in Software Engineering*. DOI: 10.1145/3084226.3084262 **PR**
- Stochel, M. et al. (2023). Business-driven technical debt management using Continuous Debt Valuation Approach (CoDVA). *Information and Software Technology*. DOI: 10.1016/j.infsof.2023.107333 **PR**
- Storey, M. (2026). From Technical Debt to Cognitive and Intent Debt. *ACM Queue*. DOI: 10.1145/3807966 **PR**
- Stray, V. et al. (2025). Developer Productivity With and Without GitHub Copilot: A Longitudinal Mixed-Methods Case Study. *Hawaii International Conference on System Sciences*. DOI: 10.24251/hicss.2026.880 **PR**
- Syahalam, I. A. et al. (2025). Accelerating the TOGAF Preliminary Phase: An Empirical Evaluation of LLM-Generated Artifacts in Banking. *13th International Conference on Orange Technology (ICOT)*. DOI: 10.1109/icot68409.2025.11425186 **PR**
- Tomaz, R. et al. (2026). Impacts of Generative AI on Agile Teams' Productivity: A Multi-Case Longitudinal Study. *IEEE/ACM Third International Conference on AI Foundation Models and Software Engineering*. DOI: 10.1145/3793655.3793728 **PR**
- Towhidnejad, M. et al. (2025). WIP: Improving Individual Productivity Utilizing SCRUM-For-One. *IEEE Frontiers in Education Conference (FIE)*. DOI: 10.1109/fie63693.2025.11328300 **PR**
- Xu, F. et al. (2025). AI-Assisted Programming Decreases the Productivity of Experienced Developers by Increasing the Technical Debt and Maintenance Burden. *arXiv*. DOI: 10.48550/arxiv.2510.10165 **PP**
- Zhang, S. et al. (2024). Empowering Agile-Based Generative Software Development through Human-AI Teamwork. *ACM Transactions on Software Engineering and Methodology*. DOI: 10.1145/3702987 **PR**
- Zhu, Y. et al. (2026). AI-Generated Smells: An Analysis of Code and Architecture in LLM and Agent-Driven Development. *arXiv*. DOI: 10.48550/arxiv.2605.02741 **PP**
- Zietsman, C. (2026). The Specification as Quality Gate: Three Hypotheses on AI-Assisted Code Review. *arXiv*. DOI: 10.48550/arxiv.2603.25773 **PP**